



Facultad de
Ciencias
UNAM

23andMe: Datos, IA y confianza en la genómica directa al consumidor

Caso de estudio

Introducción a la ciencia de datos en escenarios médico-biológicos

Física Biomédica: Temas Selectos en Biomatemáticas 2026-1

Facultad de Ciencias, UNAM

David Alexis García Espinosa

Luis Eduardo Flores Luna

15 de octubre de 2025

Resumen

Este caso estudia a 23andMe desde la perspectiva del uso de datos y la inteligencia artificial, y cómo decisiones técnicas y de gobernanza afectaron la confianza y el desempeño del negocio.

Introducción

23andMe surge con un objetivo académico y práctico: ampliar el acceso a datos genómicos y acelerar el conocimiento con evidencia del mundo real. Su propuesta inicial, basada en pruebas genéticas directas al consumidor, crea con consentimiento una base de datos amplia que combina perfiles genéticos y cuestionarios de salud. Con este acervo se realizan estudios de asociación a gran escala y se entrenan modelos que estiman riesgos comunicables al público general. En 2017, la Administración de Alimentos y Medicamentos de Estados Unidos autorizó la venta directa de ciertos reportes de *riesgo genético*, un hito que validó la aplicación y el control de calidad del producto (U.S. Food and Drug Administration, [2017](#)). A partir de 2018, una colaboración con GlaxoSmithKline buscó traducir esos datos en descubrimiento de fármacos con apoyo de ciencia de datos (GSK, [2018](#)). En 2021, la compañía anunció una fusión con una empresa de propósito especial para cotizar en bolsa con una valoración aproximada de USD \$3500 millones (23andMe Media Center, [2021](#); Reuters, [2021](#)).

¿Qué prometía 23andMe?

Hacer accesible la genómica: a partir de una muestra de saliva, entregar reportes de ascendencia, rasgos y, con autorización de la autoridad sanitaria, riesgos de salud. El modelo directo al consumidor permitió llegar a millones de personas y acumular una base de datos valiosa para investigación. En 2017, la Administración de Alimentos y Medicamentos autorizó vender reportes de riesgo genético para unas diez condiciones, marcando un hito para el modelo de consumo.

¿Cómo lograrlo? Algunos puntos ...

- **Pregunta guía 1.** ¿Cuáles son los datos mínimos para cumplir la promesa de “acercar la genómica a todos” sin invadir la privacidad? Distingue entre dato imprescindible y dato opcional.
- **Pregunta guía 2.** ¿Cómo sabrás que creas valor? Propón métricas para utilidad del usuario, validez científica y confianza.
- **Pregunta guía 3.** ¿Qué riesgos son más probables (reidentificación, sesgo, abuso de cuentas) y cuál es el más crítico? Explica por qué.
- Todo empieza capturando solo lo necesario. Los datos con nombre se guardan aparte de los datos genéticos. El usuario elige para qué se usan (producto, investigación, alianzas) y puede cambiar de opinión en cualquier momento. Cada permiso queda registrado.
- La calidad del dato sostiene el resto. Se revisan errores de laboratorio, se detectan muestras mezcladas y se completan valores faltantes con bases de referencia. Se estudia la diversidad de la base para que los modelos no confundan origen familiar con riesgo.
- Con datos limpios, se entrenan modelos de riesgo que devuelven probabilidades fáciles de entender. Se comprueba que lo que el modelo promete se cumple en la realidad y que funciona de forma parecida en distintos grupos de personas. Cada resultado muestra un rango y lo que sí se puede o no se puede concluir.
- La entrega es tan importante como el cálculo. Se usa lenguaje claro, ejemplos cotidianos y recomendaciones prácticas. Antes de publicar, se prueba con usuarios si entendieron el mensaje; si no, se corrige.
- La seguridad va de fábrica: verificación en dos pasos, sistemas que detectan comportamientos raros y límites para frenar la extracción masiva de información. Para colaborar con terceros, se usan espacios de análisis donde los socios ven resultados agregados, no datos crudos. Los modelos se vigilan en el tiempo; si aparece un sesgo, se ajusta y se informa.

Así, el usuario gana claridad y control, la ciencia avanza con datos confiables y la empresa cumple su promesa sin perder la confianza.

Si deseas explorar más a detalle en **Anexos** se encuentra una configuración básica del procedimiento para la adquisición de los datos

El punto de inflexión

En 2023, la empresa informó de un incidente de *relleno de credenciales*: atacantes usaron combinaciones filtradas de correos y contraseñas para entrar a un número reducido de cuentas, y luego extrajeron información visible de perfiles de usuarios que habían optado por la función social de parentesco. El impacto ascendió a millones de perfiles, con una cifra reportada de alrededor de 6.9 millones (23andMe Blog, [2023](#); HIPAA Journal, [2023](#)). La respuesta incluyó restablecer contraseñas y hacer obligatoria la verificación en dos pasos. En 2025, la autoridad de protección de datos del Reino Unido impuso una multa por medidas de seguridad insuficientes (Information Commissioner’s Office, [2025](#)). Ese mismo año, el tribunal autorizó la venta de la mayor parte de los activos y operaciones a una entidad sin fines de lucro, TTAM Research Institute, liderada por la cofundadora de la empresa (23andMe Media Center, [2025](#); Associated Press, [2025](#); The Guardian, [2025](#)).

Problema central

¿Cómo puede la empresa crecer con datos e inteligencia artificial sin perder la confianza del consumidor ni incumplir la regulación? El reto es mayor porque el valor del negocio depende de datos genéticos, que son especialmente sensibles. Por eso, cada decisión debe apoyarse en evidencia clara y en una comunicación comprensible para el usuario, tal como exigió la autoridad sanitaria al permitir la venta de reportes de riesgo en 2017 (U.S. Food and Drug Administration, [2017](#)). Además, si ocurre un incidente de seguridad, la organización debe demostrar salvaguardas adecuadas y notificar de forma oportuna y transparente, como reflejan el plan de acción publicado por la empresa en 2023 y la sanción del regulador británico en 2025 (23andMe Blog, [2023](#); Information Commissioner’s Office, [2025](#)).

Decisiones de producto y datos

Para publicar reportes de salud útiles y responsables, la empresa debía construir modelos que estimaran riesgos de forma precisa y, sobre todo, comprensible para cualquier persona. Eso implica calibrar los modelos y comprobar su desempeño en distintos grupos de población, además de mantener un rastro claro de cómo se tomaron decisiones técnicas (trazabilidad). Este enfoque permitió dialogar con el regulador sin promesas exageradas y con evidencia verificable. Un hito relacionado fue la autorización de informes farmacogenéticos bajo controles especiales: la autoridad sanitaria de Estados Unidos dejó claro en 2018 qué protocolos de calidad y comunicación debía seguir el producto (U.S. Food and Drug Administration, [2018a](#)). En paralelo, la colaboración con una farmacéutica se enfocó en investigación: usar datos a gran escala para encontrar posibles dianas terapéuticas, con reglas explícitas de “acceso por propósito” y entornos de análisis que evitan mover datos crudos (GSK, [2018](#)).

1. Reflexión guiada

Imagina que quieres lanzar una función para que las personas encuentren “parientes de ADN”. ¿Cómo la harías útil y segura a la vez? Empieza con tres acciones sencillas: (1) pedir verificación en dos pasos al iniciar sesión, (2) detectar comportamientos raros como muchos intentos seguidos o consultas muy rápidas, y (3) poner límites automáticos cuando alguien haga demasiadas acciones en poco tiempo. Luego revisa que estas medidas no estorben: mide el tiempo de acceso, el porcentaje de inicios de sesión exitosos y si baja la tasa de errores. Por último, prueba tu sistema con ejemplos “buenos” y “malos” para comprobar que bloquee lo indebido sin perjudicar a usuarios reales. Investiga qué ocurrió en 2023 y qué cambió la empresa, y úsalo como guía para mejorar tu diseño. (23andMe Blog, [2023](#); HIPAA Journal, [2023](#)).

Consentimiento y explicabilidad

La experiencia de consentimiento necesita ser específica por propósito, revocable y comprensible en lenguaje claro. Antes de activar la participación en investigación, un flujo con capas de información y microverificaciones de comprensión puede reducir sorpresas y alinear expectativas. La explicación del riesgo al consumidor requiere calibración transparente y ejemplos ilustrativos que no confundan probabilidad con determinismo. Estas pautas se conectan con el requisito de presentar información clara al mercado cuando se autorizan pruebas directas al consumidor (U.S. Food and Drug Administration, [2017](#)).

2. Reflexión guiada

Pausa para pensar: redacta tres frases cortas que expliquen al usuario qué datos comparte, con quién y cómo retirarse del programa de investigación. Evita jerga. Describe cómo medirías la comprensión efectiva de esos textos en una muestra de usuarios antes del despliegue.

Colaboración con terceros

Cuando la empresa colabora con una farmacéutica, los incentivos científicos y de negocio requieren salvaguardas adicionales. Un enfoque razonable es fijar acceso por propósito, entornos controlados para el análisis y auditorías periódicas. La colaboración anunciada en 2018 se fundamentó en combinar recursos genéticos a gran escala y capacidades avanzadas de ciencia de datos para acelerar la investigación traslacional (GSK, [2018](#)). La claridad sobre qué datos se comparten y cómo se protegen influye en la percepción pública y en la confianza.

3. Reflexión guiada

Pausa para pensar: si lideras datos en una colaboración así, ¿qué condiciones previas exigirías para habilitar consultas analíticas? Explica cómo comprobarías que los modelos no

se llevan información identificable y cómo publicarías métricas de transparencia sin exponer a los participantes.

Para seguir pensando...

Entre 2017–2025 aparecen tres aprendizajes claros. Primero, para obtener y mantener permisos del regulador, no basta con buenos modelos: se necesitan datos de calidad y explicaciones comprensibles para el público (U.S. Food and Drug Administration, 2017, 2018a). Segundo, la seguridad y el diseño del producto deben anticipar ataques conocidos (como el relleno de credenciales y el *scraping*); si aun así ocurre un incidente, es clave informar a tiempo y mostrar mejoras visibles (23andMe Blog, 2023; HIPAA Journal, 2023; Information Commissioner’s Office, 2025). Tercero, la forma de gobernar los datos en alianzas y en decisiones corporativas marca la confianza a futuro; la venta aprobada en 2025 a una entidad sin fines de lucro reabrió el debate sobre cómo proteger y usar información genética (23andMe Media Center, 2025; Associated Press, 2025; The Guardian, 2025).

Anexos

Elementos biológicos y configuración experimental

Elementos biológicos necesarios. La muestra primaria es *saliva humana* obtenida mediante un kit de auto-recolección que estabiliza el ácido desoxirribonucleico (ADN) desde células epiteliales bucales. El proceso requiere un sistema de recolección y estabilización (por ejemplo, dispositivos tipo Oragene), reactivos de lisis y purificación, y controles de calidad para asegurar cantidad y pureza del ADN (DNA Genotek, s.f.). El genotipado se realiza sobre *ADN genómico* usando microarreglos de polimorfismos de un solo nucleótido (SNP), con sondas oligonucleotídicas específicas y controles positivos/negativos de hibridación (Illumina, Inc., 2017).

Justificación regulatoria del diseño. La entrega de reportes de *riesgo genético* directo al consumidor exige evidencia de validez analítica y clínica, así como comunicaciones claras al usuario. La autorización de la autoridad sanitaria de Estados Unidos para reportes de riesgo genético en 2017 y la autorización con controles especiales para reportes farmacogenéticos en 2018 ilustran los requisitos que guían el flujo experimental y la comunicación de resultados (U.S. Food and Drug Administration, 2017, 2018b).

Setup del experimento (laboratorio, genotipado). Tras la recolección, el ADN se purifica, se cuantifica y se evalúa su integridad. Luego se prepara para el ensayo *Infinium* de Illumina, que incluye amplificación, fragmentación, precipitación y resuspensión, hibridación al microarreglo, extensión, tinción e imagen. El resultado es una matriz de intensidades que se convierte en *llamadas de genotipo* por marcador y por individuo, con métricas de calidad como *call rate* por muestra y por SNP (Illumina, Inc., 2017).

Setup del análisis computacional (bioinformática). El control de calidad elimina muestras con baja tasa de genotipado, heterocigosidad extrema, discordancia de sexo cromosómico o duplicados. Posteriormente se corrige por estructura poblacional mediante *análisis de componentes principales*, que ayuda a evitar asociaciones espurias y a calibrar reportes

por subpoblación (Marees et al., 2018; Patterson et al., 2006). Con los genotipos depurados, se realiza *imputación* para completar variantes no medidas usando paneles públicos (por ejemplo, el *1000 Genomes Project*) a través de servicios de imputación ampliamente usados en investigación (International Genome Sample Resource, s.f.; University of Michigan School of Public Health, 2024). El procesamiento de grandes volúmenes de datos y el filtrado estadístico se apoyan en herramientas estándar como PLINK (Purcell et al., 2007).

Entrega y comunicación del resultado. Para reportes directos al consumidor, los riesgos se presentan en lenguaje claro y con probabilidades calibradas, alineadas con las expectativas regulatorias sobre comprensibilidad y uso responsable. La trazabilidad del flujo (muestra → genotipo → control de calidad → imputación → interpretación) sustenta auditorías científicas y regulatorias (Marees et al., 2018; U.S. Food and Drug Administration, 2017).




Figura 1: Resumen de la metodología y el QR del notebook.

4. Justificación

Los profesores consideramos de utilidad incluir el caso de **23andMe** en la materia *“Introducción a la ciencia de datos aplicada a escenarios médico-biológicos”*. Este caso ofrece una ilustración clara de cómo la comprensión profunda de los **datos genómicos**, unida a buenas prácticas de **gobernanza** y **seguridad**, puede transformar una propuesta tecnológica en un servicio confiable para personas no expertas. Aunque el caso se sitúa en el contexto de la genómica directa al consumidor, los principios que aborda consentimiento informado,

comunicación del riesgo y regulación son plenamente aplicables a entornos clínicos y de investigación biomédica.

En salud y biología, interpretar correctamente datos provenientes de muestras humanas y cuestionarios, y **explicarlos con claridad**, es crucial para generar intervenciones efectivas y éticas. Al igual que en 23andMe, donde fue necesario validar modelos, calibrarlos por **subpoblaciones** y diseñar experiencias de consentimiento comprensibles, en los escenarios médico-biológicos debemos atender la **privacidad**, el **sesgo** y la **seguridad** frente a amenazas conocidas (por ejemplo, abuso de credenciales o extracción masiva de información). El caso también conecta con la colaboración ciencia-industria (por ejemplo, con farmacéuticas)

Este caso permitirá a los estudiantes reflexionar sobre la importancia de **contextualizar** los datos y de diseñar **analítica confiable** de principio a fin: desde la calidad del dato y el análisis exploratorio, hasta la validación, la comunicación al paciente y la respuesta ante incidentes. Asimismo, mostrará cómo estas decisiones pueden conducir a soluciones innovadoras en **salud pública** y **medicina personalizada**, sin perder de vista la transparencia y la confianza social.

Referencias

- 23andMe Blog. (2023, 5 de diciembre). *Addressing Data Security Concerns – Action Plan*. <https://blog.23andme.com/articles/addressing-data-security-concerns>
- 23andMe Media Center. (2021, 4 de febrero). *23andMe to Merge with Virgin Group’s VG Acquisition Corp. to Become Publicly-Traded Company*. <https://mediacenter.23andme.com/press-releases/23andme-merge-virgin-groups-vg-acquisition-corp-become-publicly/>
- 23andMe Media Center. (2025, 30 de junio). *23andMe Receives Court Approval for Sale to TTAM Research Institute, a Nonprofit Public Benefit Corporation*. <https://mediacenter.23andme.com/press-releases/23andme-receives-court-approval-sale-ttam-research-institute/>
- Associated Press. (2025, 10 de julio). *Anne Wojcicki’s nonprofit gets court approval to buy 23andMe for \$305 million*. <https://apnews.com/article/3a0724d28030734a6b4ec8b0e5c952c5>
- DNA Genotek. (s.f.). *Oragene® DNA Self-Collection Kit (OG-500): Overview*. <https://www.dnagenotek.com/ROW/products/collection-human/oragene-dna/500-series/OG-500>
- GSK. (2018, 25 de julio). *GSK and 23andMe sign agreement to leverage genetic insights for the development of novel medicines*. <https://www.gsk.com/en-gb/media/press-releases/gsk-and-23andme-sign-agreement-to-leverage-genetic-insights-for-the-development-of-novel-medicines/>
- HIPAA Journal. (2023, 5 de diciembre). *6.9 Million 23andMe Users Affected by Data Breach*. <https://www.hipaajournal.com/6-9-million-23andme-users-affected-by-data-breach/>
- Illumina, Inc. (2017). *Infinium Whole-Genome Genotyping Assay Workflow* [Technical workflow PDF]. https://www.illumina.com/Documents/products/workflows/workflow_infinium_ii.pdf
- Information Commissioner’s Office. (2025, 17 de junio). *23andMe fined £2.31 million for failing to protect UK users’ genetic data*. <https://ico.org.uk/about-the-ico/media->

- centre/news-and-blogs/2025/06/23andme-fined-for-failing-to-protect-uk-users-genetic-data/
- International Genome Sample Resource. (s.f.). *1000 Genomes Project: Summary*. <https://www.internationalgenome.org/1000-genomes-summary/>
- Marees, A. T., de Kluiver, H., Stringer, S., Vorspan, F., Curis, E., Marie-Claire, C., & Derks, E. M. (2018). A tutorial on conducting genome-wide association studies: Quality control and statistical analysis. *International Journal of Methods in Psychiatric Research*, 27(2), e1608. <https://onlinelibrary.wiley.com/doi/epdf/10.1002/mpr.1608>
- Patterson, N., Price, A. L., & Reich, D. (2006). Population structure and eigenanalysis. *PLOS Genetics*, 2(12), e190. <https://journals.plos.org/plosgenetics/article?id=10.1371/journal.pgen.0020190>
- Purcell, S., Neale, B., Todd-Brown, K., Thomas, L., Ferreira, M. A. R., Bender, D., Maller, J., Sklar, P., de Bakker, P. I. W., Daly, M. J., & Sham, P. C. (2007). PLINK: A Tool Set for Whole-Genome Association and Population-Based Linkage Analyses. *The American Journal of Human Genetics*, 81(3), 559-575. <https://zzz.bwh.harvard.edu/library/purcell-2007-plink.pdf>
- Reuters. (2021, 4 de febrero). *Branson-backed SPAC to take DNA-testing firm 23andMe public in \$3.5 bln deal*. <https://www.reuters.com/business/branson-backed-spac-take-dna-testing-firm-23andme-public-35-bln-deal-2021-02-04/>
- The Guardian. (2025, 5 de junio). *23andMe back on the auction block after former CEO makes 11th-hour bid*. <https://www.theguardian.com/technology/2025/jun/05/23andme-ceo-bid-anne-wojcicki>
- University of Michigan School of Public Health. (2024). *Michigan Imputation Server 2*. <https://imputationserver.sph.umich.edu/index.html>
- U.S. Food and Drug Administration. (2017, 6 de abril). *FDA allows marketing of first direct-to-consumer tests that provide genetic risk information for certain conditions*. <https://www.prnewswire.com/news-releases/fda-allows-marketing-of-first-direct-to-consumer-tests-that-provide-genetic-risk-information-for-certain-conditions-300436006.html>
- U.S. Food and Drug Administration. (2018a, 4 de junio). *De Novo classification for 23andMe Personal Genome Service (PGS) Pharmacogenetic Reports* [CDRH De Novo letter (PDF)]. https://www.accessdata.fda.gov/cdrh_docs/pdf18/DEN180028.pdf
- U.S. Food and Drug Administration. (2018b, 1 de noviembre). *FDA authorizes first direct-to-consumer pharmacogenetic test with special controls*. <https://www.fda.gov/news-events/press-announcements/fda-authorizes-first-direct-consumer-test-detecting-genetic-variants-may-be-associated-medication>